

CH 6

# 비선형 최적화

- 1 ) State Estimation
- 2 ) 비선형 최소 제곱

# Review

- Slam 방정식

$$\begin{cases} x_k = f(x_{k-1}, u_k) + w_k \\ z_{k,j} = h(y_j, x_k) + v_{k,j} \end{cases}$$

- CH3-4

$x_k$ : Pose

※ Slam을 계산하기 위해  $x_k$ 는 어떤 형태를 취하는가?

→ 좌표가 아닌, 의 Camera-World-Transformation행렬

SE3

- CH4-5

$z_k$ : *Landmark*의 픽셀 위치

※ 관찰 방정식  $z_k$ 는 어떻게 얻을수 있는가?

→ 핀홀카메라 모델의 경우  $sz_k = KTP \dots \{K: \text{Intrinsic}, T(SE3): x_k P(\text{Landmark}): y_j\}$

# State Estimation

- 1. Incremental 방식 :

EKF등을 사용, 직전의 데이터만을 통해  $x_k$ 를 추정

- 2. Batch Proces 방식 :

$x = \{x_1, x_2, \dots x_n\}$   $y = \{y_1, y_2, \dots y_m\}$  을 모두 고려, 처리

→ 도입이 쉽고, 일괄적으로 최소제곱법으로 최적화 가능

# State Estimation

- 관측, 모션 데이터  $z, u$  에 대한 *pose* 추정  $x, y$  확률 :  $P(x, y | z, u)$
- *Bayes Rule*

$$P(x, y | z, u) = \frac{P(z, u | x, y)P(x, y)}{P(z, u)}$$

$$\max (P(x, y | z, u)) = \max \left( \frac{P(z, u | x, y)P(x, y)}{P(z, u)} \right) \dots MAP \text{ problem}$$

$$\max (P(x, y | z, u)) = \max (P(z, u | x, y)) \dots MLE \text{ problem}$$

$$\text{관측 } z \text{ 에 대해 } \max P(x, y | z) = \max P(z | x, y) = \max N(h(x, y), Q)$$

# State Estimation

- *Gaussian*

$$P(x) = \frac{1}{\sqrt{(2\pi)^N \det(\Sigma)}} e^{-\frac{1}{2}(x-\mu)^T \Sigma^{-1}(x-\mu)}$$

$$-\ln(P(x)) = \frac{1}{2} \ln((2\pi)^N \det(\Sigma)) + \frac{1}{2} (x - \mu)^T \Sigma^{-1} (x - \mu)$$

이때  $\max(P(x)) \rightarrow \min(-\ln(P(x)))$  이고  $x$  에 대해 첫째 항 소거

관측  $z$  에 대해,  $\max P(z|x, y) = \max N(h(x, y), Q)$

$$\max N(h(y_j, x_k), Q_{k,j}) = \min((z - h(x, y))^T Q^{-1} (z - h(x, y)))$$

# State Estimation

- Motion 과 관측 데이터는 서로 독립적. 따라서
$$P(z, u|x, y) = \Pi P(u|x_{k-1}, x_k) \Pi P(z|x_k, y_j)$$

- Error 텀 (노이즈  $w_k, v_{k,j} + error$ ) 에 대해
$$\begin{cases} e_{u,k} = x_k - f(x_{k-1}, u_k) \dots N(0, R_k) \\ e_{z,j,k} = z_{k,j} - h(y_j, x_k) \dots N(0, Q_{k,j}) \end{cases}$$

$$\max P(x, y|z, u) = \min J = \Sigma e_{u,k}^T R_k^{-1} e_{u,k} + \Sigma \Sigma e_{z,j,k}^T Q_{j,k}^{-1} e_{j,k}$$

# State Estimation 예제

- 직진/후진 운동하는 모델 ( $k = 1, 2, 3$ )

$$\begin{cases} x_k = x_{k-1} + u_k + w_k & \dots w_k = N(0, Q_k) \\ z_k = x_k + n_k & \dots n_k = N(0, R_k) \end{cases}$$

$$P(x|z, u) = \prod_{k=1}^3 P(u|x_{k-1}, x_k) \prod_{k=1}^3 P(z|x_k)$$

$$\max P(x|z, u) = \min \sum_{k=1}^3 e_{u,k}^T Q_k^{-1} e_{u,k} + \sum_{k=1}^3 e_{z,k}^T R_k^{-1} e_{z,k}$$

$$x = \begin{pmatrix} x_0 \\ x_1 \\ x_2 \\ x_3 \end{pmatrix}, y = \begin{pmatrix} u_1 \\ u_2 \\ u_3 \\ z_1 \\ z_2 \\ z_3 \end{pmatrix}, H = \begin{bmatrix} 1 & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & 1 \end{bmatrix}, \Sigma = \text{diag} \begin{pmatrix} Q_1 \\ Q_2 \\ Q_3 \\ R_1 \\ R_2 \\ R_3 \end{pmatrix}$$

$$\max P(x|z, u) = \min e^T \Sigma^{-1} e$$

# 비선형 최소 제곱

- 최소 제곱 문제 :  $\min F(x) = \|f(x)\|^2$
- 선형 : 극값을 통해  $\frac{dF}{dx} = 0$
- 비선형 : Iterative한 풀이

1. 주어진 초기 값  $x_0$
2. k 번째 반복의 경우,  $\|f(x_k + \Delta x_k)\|_2^2$ 가 최소값에 도달하도록 증가분  $\Delta x_k$ 를 찾는다.
3.  $\Delta x_k$ 가 충분히 작으면 정지합니다.
4. 그렇지 않으면,  $x_{k+1} = x_k + \Delta x_k$  라고하고 2 단계로 돌아갑니다.

2 번의 방식에 따라 Newton법,  
Gauss\_Newton법, Levenberg\_Marquardt 에 대해 소개



# 비선형 최소 제곱 Newton

- 목적함수  $F$  의 테일러 근사

$$F(x + \Delta x) \approx F + J^T \Delta x + \frac{1}{2} \Delta x^T H \Delta x \dots$$

- 1차 : Gradient Descent 법 ...안정적이지 않다

$$x_{new} = x_{old} - J$$

- 2차 : Newton 법 ...  $H$ 가 복잡하다

$$\begin{aligned} x_{new} &= x_{old} + \Delta x \\ H \Delta x &= -J \end{aligned}$$

# 비선형 최소 제곱 Gauss-Newton

- $f$  의 테일러 근사

$$f(x + \Delta x) \approx f + J^T \Delta x$$

$$\min F(x) = \|f(x)\|^2 \rightarrow \min F(x) = \min \|f(x) + J^T \Delta x\|^2$$

$$\|f(x) + J^T \Delta x\|^2 = \|f\|^2 + 2fJ^T \Delta x + \Delta x^T J J^T \Delta x$$

$$\frac{\partial F}{\partial \Delta x} = 2Jf + 2JJ^T \Delta x = 0$$

$$\begin{aligned} x_{new} &= x_{old} + \Delta x \\ JJ^T \Delta x &= -Jf \quad (\mathbf{H}\Delta \mathbf{x} = \mathbf{g}) \end{aligned}$$

# 비선형 최소 제곱 Levenberg-Marquardt

- *Gauss – Newton*법의  $JJ^T$  singularity 문제, 수렴 보장문제 등을 개선하고자 함

$$\min F(x) = \|f(x)\|^2 \rightarrow$$

$$\min \|f(x) + J^T \Delta x\|^2 + \lambda \|diag(JJ^T) \Delta x\|^2$$

$$(H + \lambda D^T D) \Delta x = g$$

$\lambda$ (라그랑지안) 큰 경우 : Gradient법에 가까움

작은 경우 : Gauss\_Newton법에 가까움